

ACTIVIDAD GRUPAL — MÓDULO 4

Análisis Estadístico sobre su Propio Dataset

Diagnóstico y Predictibilidad | 92-0030 | ULACIT | Prof. Robin Sequeira

Salas de Teams — 45 minutos de trabajo | Presentación: 5 minutos por grupo

Este documento es suyo. Trabajen directamente sobre él durante la sesión.

Instrucciones Generales

El objetivo de esta actividad es aplicar los conceptos estadísticos del Módulo 4 sobre el dataset que su grupo eligió la semana pasada. No trabajan con datos de ejemplo: trabajan con sus datos reales.

Sigan el orden de las secciones. Cada sección tiene instrucciones de qué calcular en Databricks y preguntas de análisis que deben responder. Las respuestas no son código: son interpretaciones. Un número sin interpretación no responde nada.

Al final de la sesión preparan una presentación breve de 5 minutos con los hallazgos más importantes. No tienen que cubrir todo: elijan los 3 o 4 resultados que más les llamaron la atención y expliquen por qué importan para su proyecto.

Recuerden cambiar los placeholders del código (COLUMNA_OBJETIVO, COLUMNA_SEGMENTO, etc.) por los nombres reales de sus columnas antes de ejecutar.

Datos del Grupo

Nombre del proyecto: Análisis Predictivo de Precios Inmobiliarios

Dataset utilizado: trainecomerce

Variable objetivo: SalePrice

Integrantes:

- **Jean Carlos Rojas**
- **Luis Paulino Guerrero Parra**

Sección 1 — Calidad e Historia del Dataset

Esta sección conecta con el Módulo 1 (exploración inicial) y el Módulo 2 (limpieza). Antes de hacer cualquier análisis estadístico, necesitan tener claro con qué datos están trabajando y en qué estado llegaron.

Qué ejecutar en Databricks

- `mi_df.shape` — cuántas filas y columnas tienen
- `mi_df.dtypes` — tipos de datos de cada columna
- `mi_df.isna().mean().sort_values(ascending=False) * 100` — porcentaje de nulos por columna
- `mi_df.duplicated().sum()` — filas duplicadas
- `mi_df.nunique().sort_values(ascending=False)` — valores únicos por columna

Preguntas de análisis

1. ¿Cuántas filas y columnas tiene su dataset? ¿Ese tamaño es suficiente para entrenar un modelo predictivo o es limitado?

Tamaño del dataset: El dataset tiene exactamente **1,460 filas y 81 columnas** (obtenido mediante la propiedad Shape: (1460, 81)).

¿Es suficiente o limitado?: El tamaño es **suficiente** para entrenar la mayoría de los modelos predictivos estándar (como regresiones lineales, árboles de decisión o modelos de ensamble tipo Random Forest / XGBoost). No cae en la categoría crítica de ser "muy pequeño" (menos de 500 filas), por lo que no es severamente limitado.

Implicaciones para el proyecto: Al contar con más de 1,400 registros, el modelo tendrá suficientes ejemplos para aprender patrones generales sin sobreajustarse de manera inmediata. Sin embargo, dado que hay un número relativamente alto de columnas (81 características). Esto implica que el espacio de características es amplio y se requerirá aplicar técnicas de selección de variables o regularización para evitar introducir ruido y asegurar que el modelo generalice de forma óptima.

2. ¿Hay columnas con nulos? ¿Qué porcentaje representa cada una? ¿Qué decidirían hacer con esas columnas y por qué?

El dataset que seleccionamos ya tenía alguna preparación y no se encontraron datos nulls. Pero igual se generó un proceso de limpiar y eliminar datos duplicados en caso de encontrar algunos.

3. ¿Hay columnas que parecen numéricas pero están almacenadas como texto? ¿Hay fechas mal tipificadas? ¿Qué harían para corregirlo?

El dataset ya venía con datos bien definidos en tipo String y long.

4. ¿Hay columnas que son identificadores únicos (IDs) o que tienen cardinalidad muy alta y no aportan valor al modelo? ¿Cuáles eliminarían y por qué?

La columna Id tiene exactamente 1,460 valores únicos. Dado que el tamaño total del dataset es de 1,460 filas, esto demuestra una coincidencia perfecta (1:1).

Las columnas LotArea (1,073 valores únicos) y GrLivArea (861 valores únicos) también presentan una cardinalidad extremadamente alta.

Por qué ELIMINAR Id: Como cada fila tiene un número de identificación único e irrepetible, esta variable no posee ningún patrón estadístico real ni tiene relación lógica con el precio de la casa (SalePrice). Para un modelo predictivo, un ID es considerado **ruido puro**. Si se deja en el dataset, algoritmos basados en árboles de decisión o redes neuronales pueden "memorizar" que el ID número 45 vale cierta cantidad de dinero, provocando un problema grave de **sobreajuste (overfitting)**. El modelo se volvería incapaz de generalizar sus predicciones ante datos nuevos.

Por qué MANTENER LotArea y GrLivArea: Aunque su cardinalidad es muy alta (casi tanto como las filas), esto no se debe a que sean identificadores, sino a que son **variables numéricas continuas**. Representan los pies o metros cuadrados del terreno y del área habitable. En el mercado inmobiliario, el tamaño es uno de los factores más determinantes para fijar el precio; por lo tanto, aportan un valor predictivo altísimo y no deben eliminarse bajo ninguna circunstancia.

5. Comparando el estado actual de su dataset con lo que vieron en el Módulo 2 del Superstore: ¿sus datos están más o menos limpios? ¿Qué proceso de limpieza haría falta antes de modelar?

Estos datos realmente están muy limpios en comparación al superstore. Creo que sin intención se seleccionó un dataset que ya tenía cierto proceso de limpieza y fue guardado de esa manera.

Sección 2 — Estadística Descriptiva

Esta sección aplica directamente el contenido del Módulo 4. El objetivo es entender los datos desde adentro: dónde están centrados, qué tan dispersos son y si tienen comportamientos extremos.

Qué ejecutar en Databricks

```
— mi_df.describe().round(2) — estadísticos completos de las numéricas
— mi_df['COLUMNA_OBJETIVO'].mean(), .median(), .std(), .skew()
—
mi_df.select_dtypes(include='number').std().sort_values(ascending=
False).round(2) — dispersión por columna
```

Preguntas de análisis

6. ¿Cuál es la media y la mediana de su variable objetivo? ¿Son similares o hay una diferencia importante entre ellas?

Mediana: 163000.0

Mean: 180921.19589041095

Estandar: 79442.50288288662

Skew: 1.882875759768212

Los valores tienen un sesgo positivo ya que la diferencia entre la mediana y la media. Con diferencia de la tienda superstore muchos precios son controlados y de artículos pequeños pero para este dataset tenemos datos inmobiliarios que pueden variar mucho.

7. ¿Cuál es la desviación estándar de su variable objetivo? ¿Qué tan grande es en relación a la media? ¿Qué implica eso para un modelo predictivo?

Desviación Estándar: \$79,442.50

Media: \$180,921.20.

Coefficiente de Variación: 43.9%

Si se ocupa escalar los valores para evitar una distorsión.

8. ¿Cuál es el valor mínimo y máximo de su variable objetivo? ¿Tienen sentido para el contexto del problema o hay valores imposibles?

Valor Mínimo: \$34,900.00

Valor Máximo: \$755,000.00

Sí, ambos valores tienen un sentido lógico y coherente dentro del contexto inmobiliario del problema. No se detectaron valores imposibles ni errores técnicos graves

9. ¿Cuál es la columna numérica con mayor dispersión (std más alta) en su dataset? ¿Por qué creen que esa columna varía tanto?

SalePrice (**Variable Objetivo**): Desviación estándar de **\$79,442.50**.

LotArea (**Variable Predictora / Característica**): Desviación estándar de **9,981.26** pies cuadrados.

La variación en LotArea es muy grande ya que puede ver diferentes tipologías de vivienda, zonificación residenciales, naturaleza de una variable de área. El terreno es la única parte de los inmuebles no se deprecian. Los lotes pueden generar valores agregados a la venta. Este dato tiene mucho peso en los precios a pesar de las posibles desviaciones estándar.

10. ¿Cuál es el sesgo (skewness) de su variable objetivo? ¿Está sesgada a la derecha, a la izquierda, o es aproximadamente simétrica?

Sesgo (Skewness): 1.8829 (Valores > 1 indican alto sesgo a la derecha)

La gran mayoría de las casas se concentran en un rango de precios estándar tirando a bajos, pero hay un puñado de propiedades con precios excepcionalmente elevados que estiran la gráfica hacia la derecha.

11. ¿Qué diferencias encuentran entre el comportamiento de las variables numéricas de su dataset y las del Superstore que analizaron juntos? ¿Cuál les parece más complejo de modelar y por qué?

En el superstore la mayoría de variables comparten la misma naturaleza, es decir, la mayoría son monetarias pero en este caso las variables numéricas representan muchos tipos de información como longitud de metros, etc. Por eso es que las variables numéricas del nuevo dataset es más complicado que además son muchas más variables.

Por esta razón este dataset es mejor para modelar. Tiene más información y datos con los que se pueden crear diferentes modelos que expliquen el comportamiento de las ventas o precios de las casas.

Sección 3 — Distribución y Outliers

Esta sección combina lo visual con lo estadístico. El histograma y el boxplot muestran la forma de los datos. El cálculo IQR del Módulo 2 identifica los valores extremos.

Qué ejecutar en Databricks

```

— plt.hist(mi_df['COLUMNA_OBJETIVO'].dropna(), bins=40,
           color='steelblue', edgecolor='white') — histograma

— mi_df['COLUMNA_OBJETIVO'].boxplot() — boxplot para ver outliers

— Q1 = mi_df['COLUMNA_OBJETIVO'].quantile(0.25) + Q3 =
  mi_df['COLUMNA_OBJETIVO'].quantile(0.75)

— IQR = Q3 - Q1 → limite_sup = Q3 + 1.5 * IQR → limite_inf = Q1 -
  1.5 * IQR

— outliers = mi_df[(mi_df['COLUMNA_OBJETIVO'] < limite_inf) |
  (mi_df['COLUMNA_OBJETIVO'] > limite_sup)]

```

Preguntas de análisis

12. Miren el histograma de su variable objetivo. ¿Tiene forma de campana (distribución normal), está sesgado, o tiene más de un pico (bimodal)?

Al observar el histograma de SalePrice, los datos **no tienen forma de campana perfecta (distribución normal) ni muestran un comportamiento bimodal**. La forma real del gráfico es una distribución **fuertemente sesgada a la derecha (asimetría positiva)**.

El gráfico tiene un solo punto alto principal que se concentra con fuerza entre los \$130,000 y los \$180,000. Ahí es donde se encuentra la gran masa de viviendas del dataset (el mercado inmobiliario estándar o de clase media). No hay un segundo pico separado que sugiera una distribución bimodal.

13. ¿Cuántos outliers detectaron con la regla IQR? ¿Qué porcentaje del dataset representan? ¿Son casos raros o una parte significativa de los datos?

Frontera de corte superior: \$340,037.50

Cantidad de outliers detectados: 61 casas de un total de 1,460.

Porcentaje del dataset que representan: 4.18%.

No son errores aislados de tipeo (como si fuera 1 o 2 casas mal registradas), sino que representan un segmento inmobiliario real: el mercado residencial de alta gama o segmento premium.

Sin embargo, al representar menos del 5% del volumen total de registros, se confirma que el comportamiento comercial general de las viviendas en esta zona está sólidamente estandarizado en la clase media, dejando a las propiedades lujosas como anomalías de distribución

Como podemos observar tenemos menos outliers que superstore por lo que podríamos decir que la concentración de precios es más estable que las ventas de una tienda que puede tener muchos productos con muchos precios, además de posibles volatilidades masivas.

No vamos a eliminar los outliers podemos utilizar una transformación para traer estos datos más cerca de las medias y poder generar mejor resultados de valor.

14. ¿Los outliers de su dataset son errores (valores imposibles) o son casos reales pero extremos? ¿Cómo distinguen entre ambos?

Creo que identificar que tipo de outliers son con los que estamos lidiando depende del contexto y de la expertise del negocio. Los datos de nuestro dataset son datos reales pero como analista de datos lo mejor sería preguntar al negocio sobre estos para no tomar decisiones erróneas.

15. Si eliminaran los outliers de su dataset antes de modelar, ¿qué perderían? ¿Qué ganarían? ¿En su contexto de negocio tiene más sentido conservarlos o eliminarlos?

En el caso de este outliers son tan pocos que los podemos borrar sin perder mucho la precisión. Si quisiéramos conservarlos podríamos generar valores que se aproximen un poco más al centro de los datos con transformaciones. Pensamos que al ser tan pocos estos outliers borrarlos no generaron tanto impacto pero estos sí podrían tener información valiosa que nos pudiera ayudar a generar un modelo más exacto.

16. ¿La distribución de su variable objetivo sugiere que sería útil aplicar una transformación logarítmica antes de modelar? ¿Por qué sí o por qué no?

Consideramos fundamental aplicar una transformación logarítmica sobre la variable objetivo (SalePrice) antes de iniciar el modelado predictivo, ya que este procedimiento aportará una estabilidad matemática crítica al algoritmo. El dataset presenta un sesgo positivo fuerte con un coeficiente de asimetría de 1.88, valor que al superar el umbral estándar de 1, confirma técnicamente la necesidad de una transformación de escala. Adicionalmente, el análisis visual del histograma ratifica esta condición al mostrar una distribución unimodal con una alta concentración cargada hacia la izquierda (propiedades de bajo y mediano costo) y una cola derecha sumamente alargada provocada por las viviendas de lujo. Implementar esta transformación comprimirá los valores extremos y aproximará los datos a una distribución normal, optimizando de forma directa el rendimiento de los modelos basados en regresión.

Sección 4 — Correlación y Selección de Variables

Esta sección conecta el Módulo 4 (correlación) con el Módulo 3 (selección de características para el Pipeline). Las correlaciones que calculen hoy son las que van a usar para decidir qué variables entran al modelo.

Qué ejecutar en Databricks

```

— import seaborn as sns + corr =
  mi_df.select_dtypes(include='number').corr()

— sns.heatmap(corr, annot=True, cmap='coolwarm', fmt='.2f') — mapa
  de calor

—
  corr['COLUMNA_OBJETIVO'].drop('COLUMNA_OBJETIVO').sort_values(key=
  abs, ascending=False)

— corr_spearman =
  mi_df.select_dtypes(include='number').corr(method='spearman') —
  alternativa robusta

```

Preguntas de análisis

17. ¿Qué variable numérica tiene la mayor correlación (en valor absoluto) con su variable objetivo? ¿Tiene sentido esa relación en el contexto de su problema?

Sí, tiene perfecto sentido que OverallQual tenga la correlación más alta con SalePrice ($r = +0.791$). La calidad general (OverallQual) captura múltiples aspectos que impactan el precio: Calidad de materiales de construcción, Nivel de acabados (pisos, pintura), Diseño arquitectónico, Funcionalidad y durabilidad. Es una variable que sintetiza muchos factores de valor, por eso supera a variables más específicas como GrLivArea (0.709) o GarageCars (0.640).

18. ¿Hay alguna variable que esperaban que correlacionara con el objetivo y no lo hace (o lo hace muy débilmente)? ¿Qué explicación le dan a eso?

OverallCond (Condición General): -0.078. La condición/estado de mantenimiento de una casa debería impactar fuertemente el precio, pero la correlación es prácticamente cero.

Posible explicación: Confusión con OverallQual: Los compradores pagan por la calidad de construcción original (0.791), no tanto por el estado actual de mantenimiento. Una casa bien construida vale más incluso si necesita reparaciones menores.

19. Aplicando el umbral del Módulo 3 (correlación absoluta mayor a 0.2 con el objetivo): ¿cuáles de sus variables numéricas pasarían ese filtro? ¿Cuáles quedarían fuera?

Variables que PASAN el filtro ($| \text{correlación} | > 0.2$)

19 variables numéricas mantienen poder predictivo suficiente:

Correlación Fuerte (> 0.5)

- OverallQual (+0.791) : Calidad general
- GrLivArea (+0.709) : Área habitable

- GarageCars (+0.640) : Capacidad del garaje
- GarageArea (+0.623) : Área del garaje
- TotalBsmtSF (+0.614) : Área total del sótano
- 1stFlrSF (+0.606) : Área del primer piso
- FullBath (+0.561) : Baños completos
- TotRmsAbvGrd (+0.534) : Total de habitaciones
- YearBuilt (+0.523) : Año de construcción
- YearRemodAdd (+0.507) : Año de remodelación

Correlación Moderada (0.2 - 0.5)

- Fireplaces (+0.467)
- BsmtFinSF1 (+0.386)
- WoodDeckSF (+0.324)
- 2ndFlrSF (+0.319)
- OpenPorchSF (+0.316)
- HalfBath (+0.284)
- LotArea (+0.264)
- BsmtFullBath (+0.227)
- BsmtUnfSF (+0.214)

Variables que QUEDAN FUERA ($|correlación| \leq 0.2$)

14 variables numéricas serían descartadas:

- BedroomAbvGr (+0.168) : Dormitorios sobre nivel
- KitchenAbvGr (-0.136) : Cocinas sobre nivel
- EnclosedPorch (-0.129) : Porche cerrado
- ScreenPorch (+0.111) : Porche con mosquitero
- PoolArea (+0.092) : Área de piscina
- MSSubClass (-0.084) : Tipo de vivienda
- OverallCond (-0.078) : Condición general ⚠
- MoSold (+0.046) : Mes de venta
- 3SsnPorch (+0.045) : Porche tres estaciones
- YrSold (-0.029) : Año de venta
- LowQualFinSF (-0.026) : Pies² baja calidad
- MiscVal (-0.021) : Valor misceláneo
- BsmtHalfBath (-0.017) : Medio baño en sótano
- BsmtFinSF2 (-0.011) : Área terminada sótano tipo 2

Implicaciones para el Modelo:

- Reducción dimensional: De 33 variables numéricas a 19 variables (reducción del 42%)
- Beneficios: Menor riesgo de overfitting, modelo más interpretable, entrenamiento más rápido.

- Nota importante: El modelo también incluirá las variables categóricas (que se expandirán con OneHotEncoder), así que el modelo final tendrá más features

20. ¿Hay dos variables predictoras que estén altamente correlacionadas entre sí (multicolinealidad)? ¿Qué problema causaría eso en un modelo de regresión lineal?

Sí, se detectaron 3 pares de variables con multicolinealidad problemática (correlación > 0.8): Pares Problemáticos Identificados

1. GarageCars ↔ GarageArea ($r = 0.882$)

- GarageCars: capacidad del garaje (autos que caben) → $r = +0.640$ con SalePrice
- GarageArea: área del garaje (pies²) → $r = +0.623$ con SalePrice
- Por qué están correlacionadas: Miden exactamente lo mismo desde dos ángulos, garajes más grandes caben más autos.

2. GrLivArea ↔ TotRmsAbvGrd ($r = 0.825$)

- GrLivArea: área habitable total → $r = +0.709$ con SalePrice
- TotRmsAbvGrd: total de habitaciones → $r = +0.534$ con SalePrice
- Por qué están correlacionadas: Casas más grandes tienen más habitaciones.

3. TotalBsmtSF ↔ 1stFlrSF ($r = 0.820$)

- TotalBsmtSF: área del sótano → $r = +0.614$ con SalePrice
- 1stFlrSF: área del primer piso → $r = +0.606$ con SalePrice
- Por qué están correlacionadas: Arquitectónicamente, el sótano suele tener dimensiones similares al primer piso.

21. Comparen el heatmap de su dataset con el del Superstore que vieron juntos. ¿Sus datos tienen más o menos correlaciones fuertes? ¿Qué tan 'predecible' les parece su variable objetivo basándose solo en las correlaciones?

El dataset **Ecommerce** es significativamente más predecible que el **Superstore** por estas razones:

- Cantidad de predictores fuertes: Tienen 7 variables con correlación > 0.5 vs. esencialmente 1 en Superstore
- Fuerza de las relaciones: Su correlación máxima (0.79) supera claramente la del Superstore (0.49 con Profit)
- Coherencia lógica: Las variables correlacionadas tienen sentido de negocio (calidad, tamaño, garaje al precio), lo que sugiere relaciones causales reales.

22. ¿Calcularon también la correlación de Spearman? Si hay diferencias importantes entre Pearson y Spearman para alguna variable, ¿qué les dice eso sobre la distribución de esa columna?

No, no calculamos Spearman, sólo Pearson. Pero por motivo de está pregunta agregamos los cálculos y encontramos la siguiente variable:

OpenPorchSF (Área de Porche Abierto) Outliers + Ceros

- Pearson: +0.316
- Spearman: +0.478
- Diferencia: 0.162

¿Qué dice el gráfico?

- Muchas casas tienen porche = 0 (concentración en el eje Y)
- Hay outliers con porches enormes (>400 pies²)
- La distribución es sesgada con una cola larga

Interpretación: Pearson se confunde con la concentración de ceros y los outliers.
Spearman es más robusto al usar rangos.

Sección 5 — Análisis por Segmento

La correlación global a veces oculta diferencias importantes entre grupos. Esta sección conecta con la idea del Módulo 3 de que distintos segmentos pueden necesitar distintos tratamientos.

Qué ejecutar en Databricks

```
—  
mi_df.groupby('COLUMNA_SEGMENTO')['COLUMNA_OBJETIVO'].agg(['mean',  
    'median', 'std', 'count']).round(2)  
— mi_df.groupby('COLUMNA_SEGMENTO')['COLUMNA_OBJETIVO'].apply(lambda  
    x: x.skew()).round(2) — sesgo por grupo  
— Boxplot comparativo por grupo:  
    ° mi_df.boxplot(column='COLUMNA_OBJETIVO', by='COLUMNA_SEGMENTO',  
        figsize=(10,4))
```

Preguntas de análisis

23. ¿Qué grupo o categoría tiene el valor promedio más alto de su variable objetivo? ¿Cuál tiene el más bajo? ¿La diferencia es grande o pequeña en términos prácticos?

Variables con Mayor y Menor SalePrice Promedio

OverallQual — Impacto EXTREMO

- Grupo más alto: Calidad 10 → \$438,588

- Grupo más bajo: Calidad 1 → \$50,150
- Diferencia: \$388,438 (775%) — ¡Una casa de calidad 10 vale casi 8 veces más que una de calidad 1!

GarageType — Impacto MUY ALTO

- Grupo más alto: Garaje BuiltIn → \$254,752
- Grupo más bajo: Sin garaje (NA) → \$103,317
- Diferencia: \$151,435 (147%) — Más del doble de valor

CentralAir — Impacto ALTO

- Grupo más alto: Con aire central (Y) → \$186,187
- Grupo más bajo: Sin aire central (N) → \$105,264
- Diferencia: \$80,923 (77%) — Una diferencia de casi \$81K es MUY relevante

BldgType — Impacto MODERADO

- Grupo más alto: Casa unifamiliar (1Fam) → \$185,764
- Grupo más bajo: 2fmCon → \$128,432
- Diferencia: \$57,332 (45%) — Relevante pero no extrema

¿La diferencia es grande o pequeña en términos prácticos?

En este dataset, las diferencias SÍ son grandes. Regla práctica establecida:

- < 20% diferencia → BAJA relevancia práctica
- 20-50% → MODERADA — considerar en el modelo
- 50-100% → ALTA — segmentación crítica
- > 100% → MUY ALTA — prácticamente mercados diferentes

Todas las variables analizadas superan el 44% — esto significa que TODAS tienen relevancia práctica significativa para el negocio inmobiliario.

24. ¿Hay un grupo con mucha más dispersión (std más alta) que los demás? ¿Qué podría explicar eso? ¿Ese grupo es más difícil de predecir?

Sí, **Foundation='BrkTil'** es mucho más difícil de predecir que otros grupos porque:

- Alta heterogeneidad real (no es ruido estadístico)
- Muestra suficiente (n=146), confirma que la dispersión es genuina, no artefacto de muestra pequeña
- La variable es incompleta, necesita cruzarse con calidad, edad, y tamaño para predecir bien

Error de predicción alto, si el modelo predice \$132,291 para una casa BrkTil:

- El valor real puede estar entre \$77,699 y \$186,883 ($\pm \$54,592$)

- Intervalo de confianza: $\pm 41\%$ del valor medio
- Esto es enorme en la práctica, la predicción es casi inútil

25. Si entrenaran un modelo único para todos los grupos, ¿qué riesgo corren? ¿Tendría sentido entrenar modelos separados por segmento para su caso?

Un modelo único para todos los grupos "promediará" comportamientos heterogéneos, produciendo errores masivos en segmentos con alta dispersión ($CV > 40\%$). La mejor estrategia es un modelo único con variables de interacción ($OverallQual \times GrLivArea$, $OverallQual \times GarageType$) que permite coeficientes diferentes por segmento sin la complejidad de modelos múltiples. Alternativamente se podría agrupar en 3 segmentos (Baja/Media/Alta calidad), pero las interacciones logran el mismo objetivo con menos riesgo y mantenimiento más simple.

26. ¿El sesgo de la distribución de su variable objetivo cambia entre grupos? ¿Un grupo tiene distribución más normal que otro?

Sí, el sesgo de SalePrice cambia significativamente entre grupos. Por tipo de Foundation, PConc y CBlock (los dos grupos más grandes) tienen sesgo > 1.5

Sección 6 — Prueba de Hipótesis

Esta sección aplica el concepto central del Módulo 4: determinar si una diferencia observada entre grupos es real o podría ser azar.

Qué ejecutar en Databricks

```
— from scipy import stats

— grupo_A = mi_df[mi_df['COLUMNA_SEGMENTO'] ==
  'VALOR_A']['COLUMNA_OBJETIVO'].dropna()

— grupo_B = mi_df[mi_df['COLUMNA_SEGMENTO'] ==
  'VALOR_B']['COLUMNA_OBJETIVO'].dropna()

— t_stat, p_val = stats.ttest_ind(grupo_A, grupo_B)

— print(f'Diferencia: {grupo_A.mean() - grupo_B.mean():.2f} |
  p-value: {p_val:.4f}')
```

Preguntas de análisis

27. ¿Cuál fue el valor p que obtuvieron? ¿Es menor a 0.05? ¿Qué concluyen sobre la diferencia entre los dos grupos?

El valor p obtenido fue $p = 0.0000$ (prácticamente cero), mucho menor a 0.05, lo que indica que la diferencia es estadísticamente significativa. Las casas con fundación PConc tienen un precio promedio de \$225,230, mientras que las de CBlock promedian \$149,806 (diferencia de \$75,425). Esto concluye que existe evidencia sólida de que el tipo de fundación está relacionado con el precio de venta, la significancia estadística ($p < 0.05$) confirma que la diferencia es real, y la significancia práctica (50% de diferencia) sugiere que sí es relevante para estrategias de precio, valuación o segmentación de mercado.

28. Si el p-value es significativo, ¿la diferencia en valores absolutos es importante para su negocio? ¿O es una diferencia tan pequeña que no cambiaría ninguna decisión?

Como se mencionó anteriormente, la significancia práctica (50% de diferencia), (diferencia de \$75,425) sugiere que sí es relevante para estrategias de precio, valuación o segmentación de mercado.

29. ¿Qué hipótesis nula y alternativa plantearon para su prueba? Escribanlas de forma explícita.

Hipótesis planteadas en su prueba:

- H_0 (nula): El precio promedio de casas con fundación PConc es igual al de casas con fundación CBlock
- H_1 (alternativa): Los precios promedio son diferentes

¿Tiene sentido la formulación? Sí, es apropiada porque están evaluando si el tipo de fundación impacta el precio de venta, información crítica para decidir si incluir Foundation como predictor en su modelo. Con $p = 0.0000$ se rechaza H_0 , confirmando que PConc y CBlock tienen precios significativamente distintos (\$225K vs \$150K, diferencia de \$75K). Esto valida que Foundation es una variable relevante para predecir SalePrice, y justifica mantenerla en el pipeline de modelado

30. ¿Probaron más de un par de grupos? Si tienen tres o más grupos, ¿saben por qué no es correcto hacer múltiples pruebas t sin ajuste? ¿Qué alternativa existe?

No probamos más de un par de grupos.

Sección 7 — Conexión con el Pipeline del Módulo 3

Esta sección no requiere ejecutar código nuevo. Es reflexiva. Las respuestas deben basarse en lo que encontraron en las secciones anteriores.

Preguntas de análisis

31. Con base en las distribuciones que encontraron: ¿cuáles de sus variables numéricas necesitan StandardScaler antes de entrar al modelo y por qué?

Todas las variables numéricas necesitan StandardScaler por la enorme diferencia de escalas detectada en el dataset: variables de área (LotArea, GrLivArea, TotalBsmtSF) están en rangos de cientos a miles de unidades (ej: LotArea mediana 9,478 pies²), mientras que variables ordinales como OverallQual están en escala 1-10 y años como YrSold en 2006-2010. StandardScaler convierte todas las variables a media=0, desviación=1, permitiendo que el modelo compare "cuántas desviaciones estándar" cambió cada variable, independientemente de su escala original.

32. ¿Tienen variables categóricas en su dataset? ¿Cuáles necesitan OneHotEncoder? ¿Alguna podría usar codificación ordinal en lugar de one-hot?

Sí, Sí, tienen múltiples variables categóricas que actualmente procesan con OneHotEncoder como Foundation, HouseStyle, GarageType, CentralAir, BldgType, SaleType, entre otras. Sin embargo, hay un error conceptual importante porque variables como OverallQual (calidad general 1-10) y otras variables de calidad/condición (ExterQual, BsmtQual, KitchenQual) NO deberían usar OneHot porque tienen orden natural (calidad 7 está entre 6 y 8), pero OneHot las trata como categorías independientes sin relación, perdiendo esa información ordinal valiosa. Estas deberían usar codificación ordinal o mantenerse como numéricas directamente (OverallQual ya es numérica en el dataset, por eso no aparece en cat_cols). Variables nominales como Foundation (PConc, CBlock, BrkTil), GarageType (Attached, Detached, BuiltIn), o HouseStyle (1Story, 2Story, SplitLevel) sí necesitan OneHot porque no tienen orden inherente.

33. Si tuvieran que diseñar ahora mismo el ColumnTransformer del Pipeline para su dataset, ¿qué columnas pondrían en el transformador numérico y cuáles en el categórico? ¿Quedaría alguna por fuera?

- Transformador numérico (StandardScaler): LotArea, GrLivArea, TotalBsmtSF, YrSold, OverallQual (todas las variables continuas) y la variable ordinal que ya es numérica (OverallQual 1-10 conserva su orden natural).
- Transformador categórico (OneHotEncoder): Foundation, HouseStyle, GarageType, CentralAir, BldgType, SaleType (variables nominales sin orden inherente).
- Excluidas: Id (identificador sin valor predictivo), SalePrice (objetivo), Neighborhood/Exterior1st/Exterior2nd (alta cardinalidad: >10 categorías generarían demasiadas columnas dummy y causarían curse of dimensionality).

34. ¿Hay alguna variable derivada que tenga sentido crear para su dataset? Por ejemplo: una ratio entre dos columnas, una diferencia de fechas, una categorización de una variable continua.

Sí, varias variables derivadas tendrían sentido como:

- $\text{PricePerSqFt} = \text{SalePrice} / \text{GrLivArea}$: Métrica estándar en bienes raíces que normaliza el precio por área habitable; permite comparar casas de tamaños distintos y detectar si algunas áreas geográficas o estilos tienen precios premium por pie cuadrado.
- $\text{TotalArea} = \text{GrLivArea} + \text{TotalBsmtSF}$: Área total construida; captura mejor el tamaño real de la propiedad que usar GrLivArea solo.

35. Si aplicaran data leakage accidentalmente (ajustando el scaler con todo el dataset antes de dividir train/test): ¿cómo afectaría eso a los resultados de su modelo cuando lleguen al Módulo 6?

Si ajustaran el StandardScaler con todo el dataset antes de dividir train/test, el scaler calcularía la media y desviación estándar incluyendo los datos de prueba, por ejemplo la media de GrLivArea sería calculada con las 1,460 casas completas en lugar de solo las 1,168 de entrenamiento. Consecuencia crítica cuando se evalúe el modelo en el conjunto de prueba, las métricas (MAE, RMSE, R2) serán artificialmente optimistas porque el modelo indirectamente "vio" información estadística del test durante la normalización, haciendo que las predicciones parezcan más precisas de lo que realmente son. En producción real, donde lleguen casas nuevas que el scaler nunca vio, el error será significativamente mayor que el reportado en la evaluación, se estaría sobreestimando la capacidad predictiva del modelo y tomando decisiones de negocio basadas en métricas infladas que no se cumplirán en el mundo real.

Sección 8 — Síntesis y Recomendaciones

Esta sección es la más importante de la actividad y la que van a presentar frente a la clase. Integren todo lo que encontraron en las secciones anteriores para responder estas preguntas de forma articulada.

Preguntas de análisis

36. ¿Qué tan predecible les parece su variable objetivo basándose en lo que encontraron hoy? Justifiquen con al menos tres evidencias del análisis.

SalePrice es moderadamente predecible, pero con desafíos importantes. Tres evidencias clave:

1. Sesgo global alto (1.883) — Distribución fuertemente asimétrica con cola larga hacia valores extremos; los modelos lineales tendrán dificultad sin transformación log, y aún así algunos segmentos quedarán mal ajustados por la heterogeneidad del sesgo (rango de 3.094 entre grupos).
2. Heterogeneidad extrema entre segmentos — Grupos como BrkTil (CV=41.3%, sesgo=2.360) y OverallQual extremos tienen dispersión masiva dentro del mismo grupo, indicando que otras variables no capturadas (renovaciones, ubicación micro) explican gran parte de la varianza; esto limita el R2 máximo alcanzable incluso con las 17 variables que se están usando.
3. Diferencias inter-grupo son predecibles — Foundation PConc vs CBlock (\$225K vs \$150K, $p < 0.0001$), OverallQual con diferencias marcadas entre niveles, y la prueba t confirman que las diferencias entre categorías SÍ son predecibles, pero la variación dentro de cada categoría sigue siendo alta — esto sugiere que el modelo capturará bien tendencias macro (una casa calidad 8 costará más que calidad 4).

37. ¿Cuál fue el hallazgo más sorprendente de su análisis? ¿Cambió alguna suposición que tenían sobre sus datos antes de ejecutar el código?

El hallazgo más sorprendente fue que Foundation tipo PConc vs CBlock tiene \$75K de diferencia promedio ($p < 0.0001$) — un detalle arquitectónico que parece técnico/invisible resulta tener impacto de 50% en el precio, mayor que muchas características visibles como acabados o electrodomésticos.

38. ¿Qué problema técnico encontraron en su dataset que no habían anticipado? ¿Cómo afecta eso al plan de modelado?

El problema técnico más crítico fue excluir Neighborhood por alta cardinalidad (>10 categorías), cuando la ubicación es típicamente el predictor número uno del precio de vivienda en bienes raíces.

39. Si tuvieran que decirle a su cliente (o gerente) una sola conclusión de este análisis estadístico, ¿cuál sería? Formúlenla en una oración sin tecnicismos.

El precio de una casa es razonablemente predecible por su calidad y tamaño, pero sin incluir la ubicación específica del barrio (que se excluyó por razones técnicas), las predicciones tendrán un margen de error de \$30K-\$50K, suficiente para análisis de tendencias de mercado.

40. Basándose en todo el análisis: ¿qué tres acciones concretas tomarán sobre sus datos antes de empezar a modelar en el Módulo 6?

1. Aplicar transformación logarítmica a SalePrice — Con sesgo=1.883 (muy alto), $\log(\text{SalePrice})$ normalizará la distribución y reducirá el impacto de outliers extremos (\$700K+), permitiendo que modelos lineales funcionen mejor; al final devolverán $\text{np.exp}(\text{predicción})$ para interpretar en escala original.
2. Incluir Neighborhood usando Target Encoding. Actualmente excluida por alta cardinalidad (25 barrios), pero la ubicación es el predictor #1 en real estate; target encoding convierte cada barrio a un solo valor numérico (precio promedio histórico del

barrio), capturando información crítica sin explotar dimensionalidad como lo haría OneHot con 25 columnas dummy.

3. Crear variable derivada $TotalArea = GrLivArea + TotalBsmtSF$. Captura mejor el tamaño total construido que usar área habitable sola, y es una métrica estándar en valuación inmobiliaria, opcionalmente agregar $LotUtilization = GrLivArea / LotArea$ para distinguir casas compactas vs casas con mucho terreno libre (diferente perfil de comprador).

Estructura de la Presentación — 5 Minutos

Al regresar a la clase principal, cada grupo presenta 5 minutos. Pueden usar el notebook directamente o preparar 3 a 5 diapositivas. No hay formato obligatorio.

La presentación no es un reporte de todos los números que calcularon. Es una narrativa con los hallazgos más relevantes.

Sugerencia de estructura

- **Minuto 1 — El dataset (30 seg) + El problema que encontraron (30 seg):** Presenten brevemente sus datos y el hallazgo más importante o inesperado.
- **Minutos 2-3 — Tres hallazgos clave:** Elijan los tres resultados del análisis que más aportan al proyecto. Para cada uno: el número, la interpretación, y qué implica para el modelo.
- **Minuto 4 — Las tres acciones que van a tomar:** Directamente de la Pregunta 40. Concretas y justificadas.
- **Minuto 5 — La conclusión en lenguaje de negocio:** La respuesta a la Pregunta 39. Una oración sin tecnicismos.

Lo que se evalúa en la presentación

- Claridad de la interpretación. ¿Explican el número o solo lo reportan?
- Conexión con el proyecto. ¿Los hallazgos informan decisiones reales sobre el modelado?
- Pensamiento crítico. ¿Identificaron limitaciones o problemas que complican el análisis?
- Comunicación. ¿Pueden explicar un resultado estadístico sin usar jerga innecesaria?

Todos los integrantes hablan. No es aceptable que una persona presente todo mientras el resto no dice nada.

Este análisis va al Portafolio I (entrega en Semana 8). Documenten todo con celdas Markdown en el notebook: qué calcularon, qué encontraron y qué decisiones tomaron a partir de eso.

Diagnóstico y Predictibilidad | 92-0030 | ULACIT | Prof. Robin Sequeira